

邁向對話式診斷人工智慧

Towards Conversational Diagnostic AI — AMIE (Nature 2025)

謝慕揚 MD, PhD, FESC | 2026-08-02

Nature 2025 — Towards conversational diagnostic artificial intelligence
(doi:10.1038/s41586-025-08866-7)

臨床背景：為何要對話式診斷 AI

- 醫病對話是有效且富同理心照護的核心；醫療會談 (medical interview) 被稱為醫師「最強大的工具」。
- 某些情境下，**60–80% 的診斷單靠病史詢問 (history-taking alone)** 即可完成。
- 良好問診人力**全球稀缺、僅能間歇取得**。

大型語言模型 (large language model, LLM) 已能規劃、推理並維持自然對話 → 有機會發展能**在不確定性下主動蒐集資訊、進行具診斷價值對話**的醫療 AI，改善可近性、品質與健康公平 (health equity)。

AMIE 是什麼

AMIE = Articulate Medical Intelligence Explorer (Google Research / Google DeepMind)

- 專為**診斷對話 (diagnostic dialogue)** 最佳化的 LLM-based AI 系統。
- 基礎模型建於 **PaLM 2**，再經 instruction fine-tuning。
- 訓練混合：醫學推理、醫學問答、長文問答、電子病歷 (EHR) 摘要 + 真實與模擬對話。
- 核心創新：**self-play 模擬對話 + 自動回饋** (規模化到 5,000+ 疾病) + 推論階段 **chain-of-reasoning**。

目標非取代醫師，而是探索「主動問診 → 形成鑑別診斷 (DDx) → 同理溝通」整條診斷對話鏈。

訓練方法：self-play 與 chain-of-reasoning

self-play : inner + outer 雙迴圈

所有代理都由 **AMIE 自己扮演** : vignette generator 、 patient agent 、 doctor agent 、 moderator 、 critic (知道正解) 。

Inner loop : Doctor $\rightleftharpoons$ Patient 產生對話
→ Critic (知正解) 給 in-context 回饋
→ Doctor 依回饋重做 (每次迭代重複 2 次)
Outer loop : 精修對話 → 併入下一輪 fine-tuning
→ 新版 AMIE 再回 inner loop (持續學習循環)

- 每次迭代產 **11,686 段對話** , 源自 **5,230 種疾病** (常見 + 少見) 。
- 模擬對話平均約 **21 輪** (刻意模擬文字聊天式聚焦問診) 。

推論階段：chain-of-reasoning（三步驟）

「推理鏈」= 一連串**後步依賴前步輸出**的模型呼叫，每一輪回覆前執行：

步驟	內容
1. 分析病人資訊	整理正 / 負向症狀與病史、產生當前 DDx、指出缺漏資訊、評估信心與急迫性
2. 形成回應與行動	生成回覆並追問缺漏；必要時建議立即行動（如急診）；有把握則提出鑑別
3. 精修回應	依事實正確性與格式修訂：避免事實錯誤、避免重複、展現同理、清楚呈現

評估設計與結果

研究設計摘要

項目	內容
設計	Randomized, double-blind crossover ; remote OSCE 風格
介面	線上 同步文字聊天 (非語音、非視訊)
情境數	159 (India 75、Canada 70、UK 14)
專科	心血管 31、呼吸 32、腸胃 33、神經 32、泌尿 / 婦產 15、內科 16
對照	20 位全科醫師 (PCP) ，年資 3–25 年 (中位 7)
病人	20 位 validated patient-actor (India / Canada 各 10)
評分	33 位專科醫師 ，每情境 3 人盲化評分 (多數決 / 中位數)

OSCE agent = PCP 或 AMIE ; 兩者皆被要求不得透露身分。每次問診限時 ≤ 20 分鐘。

主要結果：鑑別診斷準確度 (DDx)

- AMIE 的 **top-k** 準確度在所有 k 值 (1-10) 皆顯著高於 PCP ($P < 0.05$, FDR 校正) 。
- PCP 並非每次列滿 10 診斷 (**min = 3** 、 **mean = 5.36**) ; AMIE 較完整。
- **關鍵**：相同資訊下，AMIE 產生的 DDx 較完整 → **AMIE 蒐集資訊與 PCP 相當，但解讀成 DDx 更佳**。
- 兩者多在前 **10 輪** 即取得足以正確鑑別的資訊。

非疾病狀態情境僅 10/159 ; AMIE 趨勢一致但因 n 小未達顯著。

主要結果：32 / 26 評分軸

評分觀點	優於 PCP	未達顯著的軸 (AMIE 仍非劣)
專科醫師	30 / 32	「轉診升級建議適當」、「無虛構 (confabulation) 內容」
病人 (patient-actor)	25 / 26	「承認錯誤」(適用情境少、排除多)

- 沒有任何一軸 PCP 顯著優於 AMIE 。
- 評分涵蓋 GMCPQ / PACES / PCCBP：問診結構、診斷處置、同理溝通。

同理心與 verbosity 的解讀

- patient-actor 與 specialist 一致認為 AMIE 在**同理心與溝通 (empathy & communication)** 優於 PCP，且這類病人中心軸佔多數維度。
- 但 AMIE 回應**顯著較長、較有結構 (verbose)**。

務實提醒：部分「同理心」優勢**可能源自回應較長、較有結構**，讓評分者感覺花了較多時間準備——不宜直接等同於真正的臨床同理。缺少語音 / 非語言線索也可能對醫師不利。

對醫學教育與臨床的意涵

- **問診教學**：chain-of-reasoning 「分析→追問→精修」可作為住院醫師 / NP 的結構化問診框架。
- **標準化病人 (SP) 模擬**：self-play 的 patient agent / critic 示範**可規模化、可回饋**的問診練習。
- **診斷推理訓練**：AI 於相同資訊下 DDx 更完整 → 教學應強化「從已知資訊推出完整鑑別」。
- **可近性 / 公平**：願景是把世界級問診品質規模化到資源不足地區。
- **人機互補**：結合醫師對非語言線索的判讀 + LLM 的結構與完整鑑別。

限制（務必謹慎解讀）

1. 介面不符真實臨床：同步文字聊天對 PCP 不熟悉，不代表一般（遠距）醫療實務。
2. 模擬病人非真實病人：無法涵蓋真實背景全貌；AMIE 對低英語識讀病人表現明顯下降。
3. 情境偏疾病狀態：僅 10/159 為無疾病，不符基層「多在排除疾病」的現實。
4. 公平 / 偏誤未充分評估；5. 尚非真實部署 — 需不確定性估計、轉交人類醫師、合格醫師在環把關。作者：應以謙遜與謹慎詮釋。

Take-home messages

AMIE 是對話式診斷 AI 的重要里程碑，但成果來自受限模擬情境 + 文字聊天 + 模擬病人。

- 優勢在「把資訊解讀成完整 DDx」，非「問到更多」。
- 30/32、25/26 軸優於 PCP，但介面對醫師不熟悉是關鍵前提。
- 「同理心」高分部分可能只是回應較長較有結構。
- 對醫學教育：重點是結構化診斷推理與可規模化問診模擬，不是取代醫師。

參考文獻

1. Tu T, Schaekermann M, Palepu A, et al. Towards conversational diagnostic artificial intelligence. *Nature*. 2025;642(8067):442-450.
<https://doi.org/10.1038/s41586-025-08866-7>
2. McDuff D, Schaekermann M, Tu T, et al. Towards accurate differential diagnosis with large language models. *Nature*. 2025.
<https://doi.org/10.1038/s41586-025-08869-4>

縮寫：LLM 大型語言模型；DDx 鑑別診斷；OSCE 客觀結構式臨床測驗；PCP 全科醫師；EHR 電子病歷；SP 標準化病人；NP 專科護理師；FDR 偽發現率；patient-actor 扮演病人的受訓演員。

本投影片為讀書會共筆整理，僅供教學參考；數據均引自原文。