

醫學研究使用大型語言模型的實務指引

Tutorial: Guidance on the Use of Large Language Models for Medical Research

Jin Q, et al. *Nat Protoc.* 2026 — NIH / National Library of Medicine

謝慕揚 MD, PhD, FESC | 2026-08-29

原文連結 — <https://doi.org/10.1038/s41596-026-01408-z>

作者群主體來自維護 PubMed 的 NLM，不含模型廠商，聲明無利益衝突

一句話總結

這是 NIH / NLM 寫給臨床與研究人員的「LLM 落地作業指引」，不是綜述、也不是評論。

核心主張很直白：

現在大多數人使用 LLM 的方式 — 打開 ChatGPT 隨手問一問 (ad hoc prompting) — 對醫療任務而言遠遠不夠。

這種落差會同時造成 低度利用 (underutilization) 與 誤用 (misapplication)。

解方：一條有紀律的流水線 + 10 條最佳實務

對臨床端最關鍵的三條

1. 先收集約 100 個測試案例再開始

沒有測試集就沒有品質可言

2. 不要把可識別的病人資料放進非 HIPAA 合規的服務

透過 API 的專有模型通常不符合 HIPAA

3. 不要用選擇題成績挑模型

MCQ 表現與真實臨床效用**不相關**

為什麼這篇值得讀

1. 來源權威且中立

NLM (PubMed) + Columbia、Yale、UIUC、UVA、Weill Cornell、FSU、NIH Clinical Center

沒有模型廠商；聲明無利益衝突

2. 把「怎麼做」寫成可執行步驟

附公開教學程式碼 repo：`ncbi-nlp/LLM-Medicine-Primer`

3. 明確指出醫界最常見的兩個錯誤

用 web app 處理病人資料、用考試分數挑模型 — 這兩點天天發生

一句話：把這篇當成 LLM 版的 CONSORT / STROBE —
它規範的不是結果，而是流程的可信度。

整體框架

五個階段

五階段流水線

1. 任務形成 Task formulation
抽象需求 → 具體任務；辨識屬於五大能力的哪一種
★ 收集約 100 個測試案例 (input + output)
↓
2. 模型選擇 LLM selection
三個考量：任務與資料 / 效能要求 / 存取介面
硬限制：資料型態 (modality)、context window
↓
3. 提示工程 Prompt engineering
FSL → CoT → RAG → Tool learning ; temperature = 0
↓
4. 微調 Fine-tuning (只有三種情況才需要)
全量微調 vs PEFT / LoRA
↓
5. 部署 Deployment
法規遵循 / 系統穩健性(公平性) / 成本 / 上線後監測

關鍵順序：提示工程排在微調前面 — 多數醫療任務不需要微調

階段一

任務形成 Task Formulation

先問：這件事屬於 LLM 的哪一種能力？

能力	醫療應用範例	評估方式
知識與推理	醫學問答、臨床決策支援、 病人與試驗配對	先比對短答案，滿意後再看解釋
摘要	長病歷→出院病摘；文獻→系統性回顧	BLEU / ROUGE / BERTScore ⚠
轉譯	跨語言、醫學教育、 醫病溝通 （換語氣寫給不同對象）	同摘要
結構化	自由文字→結構化欄位；DRG 分類；概念關係抽取	precision / recall / F1
多模態	放射報告生成；整合 EHR 病史 + 當次影像	同推理

💡 **Translation 不只是中英翻譯** — 也包括**寫作風格轉換**
(把技術性說明改寫成病人聽得懂的話) → 這是衛教最實際的用途

一個反直覺的重點

在「結構化」這類較簡單的任務上，
LLM 常常打不贏經過微調的 BERT 類模型。

LLM 的主場是需要醫學知識與臨床推理的任務，不是所有 NLP 任務。

最重要的一步：先建測試集

Best practice 1：收集約 100 個測試實例，每個都要有 input 與 output。

依據數個 LLM 醫學評估研究的經驗，建議 ~100 個實例，要求多樣 (diverse)

為什麼這是整條流水線的地基？

- 沒有測試集，無法比較兩個 prompt 誰比較好
- 沒有測試集，無法知道換模型之後有沒有變差
- 沒有測試集，無法在部署後偵測退化

🔑 這是本文對臨床端最重要、也最常被跳過的一條。
大多數人的做法是「試幾個例子看起來不錯就上線」——
那不是評估，那是印象。

階段二

模型選擇 LLM Selection

隱私與法規 — 臨床端的第一道關卡

⚠ 作者的明確陳述

透過 API 存取的專有模型（如 OpenAI 的 GPT-5）**通常不符合 HIPAA**，
因此不應用於病人資料。

Azure 與 Anthropic 提供符合 HIPAA 的 LLM 存取。
或者使用本地端模型（Llama、Mistral）以獲得更強的隱私控制。

做法	評價
醫院在 安全本地伺服器 用 完全去識別化 病歷微調，限授權內部人員	✅ 朝向合規
把 可識別的病歷 上傳到 公開 LLM API	❌ 很可能違法，尤其當該 API 會用輸入去訓練模型

準則：使用前**先讀完**供應商**使用者條款**

資料模態 (Modality) — 硬限制

資料型態	需求
放射 / 病理 2D 或 3D 影像	需要 超越純文字 的模型 (o3-mini、Llama 3 不行)
醫療對話 (音訊)	可先轉錄成文字，再用文字模型
基因體 (DNA 序列、RNA 表現)	需要 omics 判讀知識
時序 (生命徵象監測)	需能分析結構化 EHR 的長時間模式

⚠ 基因體與時序資料雖可表示成純文字，但一般 LLM 能否在不經額外訓練下有效處理，仍不清楚

Best practice 3：確認任務必需的模態，選擇支援該模態的 LLM

Context Window — 另一個硬限制

1 個 token $\approx$ 0.8 個英文字
一篇 PubMed title + abstract $\approx$ 250 字 $\approx$ 300–400 tokens

模型	Context window	約可容納摘要數
Llama 3.0	8,000 tokens	~20 篇
Claude 4.5 Opus	200k tokens	~800 篇
GPT-5	400k tokens	~1,600 篇
Gemini 3.0	1M tokens	~2,500 篇

⚠ 長 context 不是萬靈丹：作者點名 **lost-in-the-middle** — 模型會用不到放在提示中間的資訊，這問題在長 context 模型上同樣存在

實務啟示：重要的東西放頭尾，不要埋在中間。

效能評估：兩種路線

	自動評估	臨床評估
方法	MedQA-USMLE、PubMedQA、MedMCQA 等 選擇題	真實情境測試，如 RCT
優點	可規模化、可作為起點	黃金標準 ，與病人照護相關
缺點	⚠ 分數高不等於臨床效用好	耗費大量人力，常拿不到

⚠ 本文最重要的警告之一

在多選題 benchmark 上分數更高，不必然轉換為更好的臨床效用。
因為真實應用中**根本沒有選項可選**；多項研究顯示
MCQ 表現與真實任務效用不相關。

較有前景的方向：**HealthBench**（評分表）、**Chatbot Arena**（偏好）

Best practice 4：優先依臨床評估選模型；拿不到才用自動評估**篩選**候選

存取介面：三選一

介面	優點	缺點
Web 應用 (ChatGPT)	便宜、易用	✗ 無法控制模型行為、無法規模化評估；多數不具明確 HIPAA 合規；通常連 temperature 都設不了
模型 API	比自架容易；部分提供 HIPAA 合規；可控參數	專有模型客製化受限
本地部署	最大控制權與隱私；可取得下一個 token 的原始機率分布	硬體與技術門檻高

⚠ 作者明確不建議在開發階段使用 web 應用

總結權衡：尖端專有 LLM 一般任務表現較好，但客製化、隱私、安全掌控較少；
開源 LLM 客製化與安全性較佳，但開發與部署兩端門檻都更高

階段三

提示工程 Prompt Engineering

核心方法論

定義：設計與最佳化提示，以有效引導 LLM 產生準確、連貫回應的過程

核心觀念：不修改模型參數就能引導多樣行為；任務越複雜，提示越需精緻

自動化：可用 DSPy、TextGrad 讓 LLM 依效能回饋自動調整提示

🔑 作者給的方法論主軸

先分析錯誤 (error analysis)，再依錯誤型態選技術。

例：錯誤肇因於缺乏醫學知識 → 用 RAG 把相關資訊餵給模型

四項核心技術 (1 / 2)

① FSL — Few-Shot Learning

- 提示中放入**少數範例**，每個都要**同時含輸入與期望輸出**
- 範例應**有代表性且多樣**；分類任務應**展示所有可能標籤**
- 進階：依待預測實例的**語意相似度動態生成範例**
- **Best practice 5**：從 **zero-shot** 開始，逐步加範例以提升效能或處理邊緣案例

② CoT — Chain-of-Thought

- 最簡單做法：輸入末尾加上 "**Let's think step-by-step**"
- 在複雜醫療決策中特別有用：**推理說明可提升效能，也幫助醫師理解與驗證**
- **Best practice 6**：把 CoT 當成預設值

💡 一個只給答案的 AI **無法被查核**；給出推理的 AI 才可能被醫師**驗證與否決**
這是**安全性議題**，不只是效能議題

四項核心技術 (2 / 2)

③ RAG — Retrieval–Augmented Generation

解決兩個醫療上特別危險的問題：

問題	說明
幻覺 (hallucination)	生成不正確的內容或不存在的參考文獻
知識過期	參數中的知識停留在訓練時點

- 建議語料：系統性回顧、醫學教科書、臨床指引
- 常用資源：PubMed (>3,900 萬篇摘要)、PubMed Central (>700 萬篇開放全文)

④ Tool learning (function calling)

- 資料庫工具、醫學計算機；例：給 LLM 「讀取原始 EHR」 的工具

Temperature 與輸出格式

Best practice 8

temperature 從 0 開始 — 取得確定性結果以確保可重現性
只有需要多樣回應（如 ensembling）時才調高

指示 LLM 產生結構化輸出，例如 JSON 字典 —
主要考量是自動解析回應的難易度

⚠ Temperature 通常可透過 API 或本地端設定，但 web app 通常不行

→ 這是不建議用 web app 做開發的另一個具體理由

提示工程的其他細節

多模態資料轉成文字提示

- 單細胞 RNA 定序可轉成含**基因標記與表現量**的文字提示
- 生物感測器訊號可轉成文字，生成**個人健康洞察與運動建議**

早期迭代階段可探索的經驗性調整

- 聚焦的範例 (focused examples)
- **上下文擺放與包裝的位置**
- 多樣本 (multishot) 範例的組織方式

這些屬於原文所稱「較為經驗性 (anecdotal) 的提示微調」，特別適用於**早期迭代開發階段**。

階段四

微調 Fine-Tuning

什麼時候才需要微調？

只有三種情況才考慮 (Best practice 9)

1. 提示工程技術 (FSL、RAG) 已無法充分改善結果
2. 有大規模、現成的高品質訓練資料
3. 可用的提示長到成本上不可行

 反過來說：這三條都不成立，就不要微調。

這是本文對想「訓練自己的醫療 AI」的團隊最務實的提醒。

全量微調 vs PEFT

	Full fine-tuning	PEFT (如 LoRA)
更新範圍	全部參數	遠少於全模型的參數
適合資料	較大、較多樣	較小、較專一 (避免 overfitting)
硬體需求	高	大幅降低
效能	—	常與全量相當，低資料量時甚至更好

具體案例：用 quantized LoRA (QLoRA) 微調 LLM 做臨床文本摘要，
僅用數千筆訓練實例 + 一張 NVIDIA Quadro RTX 8000 GPU 即達成有效結果

⚠ 與提示工程一樣，微調後模型必須在「獨立測試集」上評估，驗證確實提升

階段五

部署 Deployment

法規遵循

- 須遵守 **HIPAA** 與 **GDPR**
- 使用專有 LLM 時**必須確認平台符合 HIPAA**
- 作者具體點名：
 - **OpenAI API** 目前不符合 HIPAA
 - **Azure** 提供符合 HIPAA 的 OpenAI 模型存取
 - **Anthropic** 為 Claude 模型提供 **HIPAA 認證的 API 託管**

⚠ LLM 這類 AI 演算法有可能被視為醫療器材而受管制 —
尤其在**臨床場域使用或用於決策支援**時，
需符合 **FDA** 或其他主管機關對**醫材軟體**的規範

Best practice 10：謹慎選擇符合法規與臨床標準的協定，並**持續監測**

系統穩健性與公平性

⚠ 作者的明確警告

即使是最成功的專有模型也可能展現種族偏誤。

研究顯示，當提供僅在種族上不同、其餘完全相同的病人描述時，LLM 可能對治療、費用或預後給出不同的預測。

這種差異在正式運作時會造成醫療不平等 (healthcare disparities)。

因此：部署前必須評估模型公平性

若無法檢視資料或演算法（許多專有模型即是如此），
仍可**使用既有 benchmark 資料集評估**，了解是否存在偏誤及其程度

成本

專有模型（作者實例，截至 2025 年 12 月）

Google Gemini 3.0
input : US\$2 / 1M tokens (提示 < 200k tokens 時)
output : US\$12 / 1M tokens

實例：處理 1,000 份典型 MIMIC-III 出院病摘
≈ 400 萬 tokens ≈ US\$8 (僅計提示 token；輸出另計)

開源模型：前期硬體（GPU） + 持續維運

模型規模	硬體需求
7–8B 參數 instruction-tuned	常可用單張高記憶體 GPU（如 A100 40GB）；容忍延遲甚至可用 CPU
70B 參數	通常需多 GPU 或 tensor-parallel serving

節省技巧：新模型（如 Qwen3）提供 FP8 變體，GPU 記憶體用量約減半（vs FP16）

上線後 (Post-deployment)

持續監測是必要的。作者強調四件事：

1. **定位** — 確保 LLM 輸出被負責任地當作輔助工具，而非取代醫療專業人員的判斷
2. **訓練** — 協助醫療人員理解如何解讀與運用輸出、並管理潛在風險
3. **社群參與** — 透過社群諮詢委員會與病人小組收集回饋，貼近真實世界多樣性
4. **模型生命週期管理** ⚠️

模型的淘汰或替換，可能需要重新實作提示、重新驗證效能、重新認證安全與合規

🔑 **第 4 點最容易被忽略**：你依賴的模型版本會被下架。

要問的不是「這個 prompt 現在好不好用」，
而是「換模型的那一天，我們要花多久重跑驗證？」

→ 這就是為什麼 **Best practice 1**（先建 100 個測試案例）是整條流水線的地基

評估

為什麼「考試考很高」不等於「好用」

論證結構

常見的推論（錯誤）

「這個模型 USMLE 考 90 分 → 它可以看門診」

作者的反駁

- ① 真實臨床「沒有選項可選」
MCQ 提供 5 個選項，其中必有 1 個正確
真實情境是開放式的，且可能沒有正確答案
- ② 多項研究顯示 MCQ 表現與真實任務效用「不相關」

正確的做法

自動評估 → 只用來「篩選」候選模型（可規模化、便宜）

↓

臨床評估 → 才是黃金標準（如 RCT），但耗費人力

↓

開放式評估是有前景的中間路線

- HealthBench（以評分表 rubric 為基礎）
- Chatbot Arena（以偏好 preference 為基礎）

💡 **對醫學教育的延伸：**這和「筆試成績能不能預測臨床表現」是同一個問題。

作者的立場等同 Miller 金字塔 — **knows ≠ knows how ≠ shows how ≠ does**。

用 MCQ 挑 LLM，就像用筆試挑住院醫師。

十條最佳實務

最佳實務彙整

#	最佳實務	階段
1	收集約 100 個測試實例（含 input 與 output）	任務形成
3	確認必需的資料模態，選擇支援該模態且 context window 足夠的 LLM	模型選擇
4	優先依臨床評估選模型；無法取得時才以自動評估篩選候選	模型選擇
5	從 zero-shot 開始，逐步加範例以提升效能或處理邊緣案例	提示工程
6	把 CoT 當作預設，提升可解釋性與效能	提示工程
7	善用 RAG 與工具呼叫 (function calling)	提示工程
8	temperature 從 0 開始；輸出結構化格式（如 JSON）	提示工程
9	只在三種情況下才微調	微調
10	選擇符合法規與臨床標準的協定，並持續監測（公平性、偏誤、生命週期）	部署

註：原文 Box 2 共列 10 條；第 2 條於內文未被直接引用，完整內容請參閱原文 Box 2。

接到我們自己的工作流

實務對照表

⚠ 本頁為講義整理者的延伸應用建議，非原文內容

我們的既有工作	對應段落	具體做法
每週期刊文獻回顧	Summarization + RAG	用 PubMed / PMC 當檢索語料；要求 JSON 結構化輸出（title / journal / DOI / 結論方向）以便自動核對
「不要根據 abstract 猜結論」的紀律	幻覺與知識過期	這正是 RAG 存在的理由；但 RAG 不保證正確 — 交叉查證不可省
衛教單張、醫病溝通改寫	Translation（風格轉換）	明確指定對象（病人 / 家屬 / 住院醫師）與閱讀程度
病歷結構化、資料擷取	Structurization	⚠ 注意：這類任務微調過的 BERT 可能更好也更便宜
任何碰到病人資料的事	法規遵循	✗ 不要放進未聲明合規 / 未經院方核可的服務
想評估「這個 AI 好不好用」	BP 1 + 評估章節	先建 ~100 題自己的測試集；不要用它考 USMLE 來決定

限制與該注意的地方

1. 這是 Tutorial，不是系統性回顧或實證指引

提供的是**專家共識性質的操作框架**；「~100 個測試實例」是**經驗法則**，非檢定過的閾值

2. 技術細節會快速過期

模型名稱、context window、價格（明確標註 "as of December 2025"）都會變

→ **框架會存活，數字不會**

3. 合規陳述有時效與地域性

4. 沒有提供醫療機構層級的治理範本（採購、稽核、事故通報）

5. 公平性章節指出問題，但未給出可操作的檢測流程

⚠ **給台灣讀者**：文中所有 HIPAA 建議，應轉譯為

「符合個資法、通過院內資安與 IRB 審查的路徑」。

不要因為某服務標示 HIPAA 合規，就認定在台灣可直接用於病人資料。

Take Home

Take Home (1 / 3)

Pearl 1：這是 NIH / NLM (PubMed 的維護者) 寫的操作指引，作者群**不含模型廠商**、聲明無利益衝突。定位是**方法論工具書**，不是綜述。

Pearl 2：框架五階段 — 任務形成 → 模型選擇 → 提示工程 → 微調 → 部署。注意**提示工程排在微調之前**：多數醫療任務**不需要微調**。

Pearl 3 (最常被跳過)：先收集約 100 個測試實例再開始。沒有測試集就無法比較 prompt、無法察覺換模型後的退化、無法在上線後偵測劣化。

Pearl 4 (臨床紅線)：透過 API 的專有模型通常不符合 HIPAA，不應用於病人資料。Azure 與 Anthropic 提供 HIPAA 合規存取；或改用本地模型。**把可識別病歷丟進公開 API 很可能違法**，尤其當該 API 會用輸入去訓練模型時。

Take Home (2 / 3)

Pearl 5 (挑模型的紅線)：不要用 MCQ 成績挑模型。真實情境沒有選項可選；多項研究顯示 MCQ 表現與真實任務效用不相關。自動評估只能用來篩選，臨床評估才是黃金標準。

Pearl 6 (四件武器)：FSL (從 zero-shot 開始加)、CoT (設為預設，因為可被醫師驗證)、RAG (對抗幻覺與知識過期，用系統性回顧 / 教科書 / 指引當語料)、Tool learning (計算交給計算器)。temperature = 0 以求可重現。輸出 JSON 以便解析。

Pearl 7：Web app 不適合開發 — 無法控制參數 (連 temperature 都設不了)、無法規模化評估、多數不具明確 HIPAA 合規。

Pearl 8：LLM 不是所有 NLP 任務的答案。在結構化這類簡單任務上，微調過的 BERT 常常更好。LLM 的主場是需要醫學知識與臨床推理的任務。

Take Home (3 / 3)

Pearl 9 (公平性)：僅改變種族、其餘完全相同的病人描述，LLM 可能給出不同的治療、費用或預後預測。部署前必須評估公平性。

Pearl 10 (生命週期)：你依賴的模型會被下架。淘汰或替換需要重新實作提示、重新驗證效能、重新認證合規 — 這正是 Pearl 3 的測試集真正發揮價值的時刻。

Pearl 11 (台灣在地化)：所有 HIPAA 建議須轉譯為個資法 + 院內資安 + IRB 的路徑。
HIPAA 合規 ≠ 台灣可用。

參考文獻

1. Jin Q, Wan N, Leaman R, Tian S, Wang Z, Yang Y, Wang Z, Xiong G, Lai P-T, Zhu Q, Hou B, Sarfo-Gyamfi M, Zhang G, Gilson A, Bhasuran B, He Z, Zhang A, Sun J, Weng C, Summers RM, Chen Q, Peng Y, Lu Z. Tutorial: guidance on the use of large language models for medical research. *Nat Protoc.* 2026. PMID: [42498804](#) · PMC13454964
2. 教學程式碼 (NCBI / NLM 官方 repository) : [ncbi-nlp/LLM-Medicine-Primer](#)
3. PubMed 檢索入口 : <https://pubmed.ncbi.nlm.nih.gov/> (超過 3,900 萬篇摘要)
4. PubMed Central : <https://www.ncbi.nlm.nih.gov/pmc/> (超過 700 萬篇開放取用全文)

原文內文引用之次級文獻 (GPT-5、Claude 4.5、Gemini 3、Llama 4、DeepSeek-R1、MedQA-USMLE、PubMedQA、MedMCQA、HealthBench、Chatbot Arena、DSPy、TextGrad、LoRA、MIMIC-III 等) 請逕參閱原文 References 章節。

文獻資訊經 PubMed 查證取得。

謝謝聆聽

Q & A

謝慕揚 MD, PhD, FESC

本內容為讀書會共筆整理，僅供醫療專業人員教學參考。

文中 HIPAA / GDPR / FDA 相關陳述為原文對美國與歐盟情境之描述，

在台灣應依個資法、院內資安規範與 IRB 審查辦理，不可直接套用。